國立高雄大學　Term Project I

資安文件搜尋引擎

從七站文件到可查證的搜尋結果

Web Search Engine　／　開發、評估與展示

專題範圍與搜尋流程

選題	把自主滲透 Agent 的構想收斂成可檢索的資安文件。
離線建置	從種子網址收集正文，經過斷詞與正規化後建立倒排索引。
線上查詢	從索引找候選、計算相關分數、排序並顯示原文。

課程基準收錄七站、980 頁

980 頁

固定課程快照 · 七個來源站

來源

Kali、Nmap、Metasploit、Wireshark、mitmproxy、Frida、GTFOBins

範圍

以站點、路徑與配額限定收錄範圍，分開保存後續實驗快照。

早期排名試錯與課程基準

標題加分	固定加分一度讓標題命中壓過正文分數。
同義詞	有些工具更容易找到，sqlmap 卻從第 1 名掉到第 4 名。
課程基準	預設回到純 TF-IDF cosine。BM25、長度正規化與詞覆蓋優先各自比較。

判定標準改變後，分數也改變

0.96

早期以關鍵字快速判定

0.42

按題意重讀全文後的純 TF-IDF

兩次的相關性規則不同。後續排序比較共用同一份標註。

詞的位置加快片語查詢

49.0 → 4.4 ms

片語加排除的代表查詢

47.9 → 9.8 MB

v8.1 壓縮前後索引大小

壓縮前後 414 次比較的結果、分數、摘要與解釋相同。

04　固定題組比較

九種設定共用全文判定

0.400

純 TF-IDF · 保留題平均 P@5

0.625

BM25 · 保留題平均 P@5

46 題、654 組題目與文件配對。24 道保留題於設定選定後評估。

指定來源與文件用詞

指定站名	輸入 GTFOBins 時，舊排序把其他網站的普通詞命中排得更前。
詞彙差異	使用者問 libraries，Frida 文件以 modules 描述同類內容。
調整結果	將網址網域與明確術語納入排序。兩道已知題分別達到 0.80 與 0.40。

同一範例需要同時符合功能與權限

原排名的問題	同一頁可能分別提到 sudo 和反向 shell，兩者出現在不同範例。
證據配對	在同一例子內核對功能與執行情境，另外辨識明示的刪檔。
已知題結果	反向 shell 0.00 到 0.60。sudo 一般寫檔 0.20 到 1.00。

05　v8.5

站內附加寫入原本缺少文件

0 / 5

原快照 · 已知附加題

3 / 5

補收三頁後 · 同一道題

再按附加證據重排，第三篇由第 4 名升到第 3 名。

站外附加的三篇文件如何進入前三

文件	舊排序	僅排除指定站	來源與效果排序
Debian hosts	26	22	1
Ubuntu vsftpd	347	245	2
Ubuntu Apache2	549	447	3

同一份 986 頁索引。查詢要求站外來源與 sudo 附加。

覆寫、附加與刪檔的證據

覆寫	原語料已有範例。只看到輸出路徑還不足以證明會取代既有內容。
附加	範例必須保留原內容，且實際寫入端符合指定權限。
刪檔	文件明說會移除目標時，歸到刪檔效果。

06 v8.6

12 道新題的平均 P@5 提升

0.1833

v8.5 對照排序

0.6333

v8.6 來源與同例證據排序

8 題進步、4 題持平。兩版共用 986 頁快照與 LM 判定。

目前的限制與效能代價

零分案例	跨站比較與站外 SUID 附加仍為 0。站外三篇正例都使用 tee。
時間代價	同一輪暖機查詢中位數由 2.56 ms 增至 2.98 ms。
評估來源	LM 判定另列。課程基準、保留題和效果新題各用自己的評估結果。

DEMO　5 分鐘

現場展示

01	課程搜尋	輸入 SQL injection 查詢，展開逐詞計分與索引原文。
02	v8.6 對照	使用站外附加範例，固定 986 頁，切換舊版與新版並查看證據。
03	評估紀錄	查看 P@5、判定來源與可下載的判定依據。

本機網址　http://127.0.0.1:5057/

附錄 I 語料版本與評估用途

980 頁	原七站快照。課程 TF-IDF 基準與 v8.2 九種設定。
983 頁	v8.5 實驗。補收三篇 GTFOBins 附加文件。
986 頁	v8.6 實驗。另補收三篇 Ubuntu／Debian 文件，同快照比較兩種排序。

附錄 | v8.6 網頁操作畫面

